Introdução à Aprendizagem Automática 2026/2027

Aprendizagem Não Supervisionada - Mini Projeto de Laboratório I

6 de outubro de 2026

1 Introdução

Este mini-projeto tem como objetivo a familiarização prática com os algoritmos de aprendizagem não supervisionada lecionados nas aulas teóricas. Em particular, é esperado que os alunos apliquem os conhecimentos adquiridos e os expandam seguindo um conceito de aprendizagem ativa, tendo por base um conjunto de dados reais. Este mini-projeto terá componentes de programação (implementação de algoritmos), aplicação dos algoritmos para visualização e interpretação/análise dos resultados. As aulas de laboratório servirão para acompanhar e avaliar de forma contínua a progressão dos projetos, mas é esperado que os alunos dediquem tempo ao trabalho fora das aulas de laboratório.

O trabalho deverá ser realizado em **grupos de 2 alunos**, sendo que cada grupo deve trabalhar sozinho. A linguagem de programação a usar será o **Python**. Recomenda-se a instalação de, pelo menos, as seguintes bibliotecas: *numpy, scipy, matplotlib, pandas, scikit-learn.* Alternativamente, os alunos poderão usar o **Google Colab**[*]como plataforma para implementarem todo o código do projeto. O Colab tem o benefício de que pode ser associado a uma conta de endereço Gmail, interliga com o Google Drive e não necessita de instalação das bibliotecas mais populares.

2 Submissão e Regras Sobre o Uso de IA

Cada grupo deve submeter um **ficheiro zip** no Fénix até dia **17 de Outubro de 2026**, com os seguintes ficheiros:

- Um **ficheiro Python**, idealmente um *Jupyter Notebook*, contendo todo o código desenvolvido para o projeto. Código que faça parte da avaliação, nomeadamente que corresponda a perguntas para escrita de funções, deve estar claramente indicado com comentários.
- O **PDF do enunciado preenchido** com as respostas às questões nos campos indicados - isto pode ser feito preenchendo diretamente o PDF num browser ou num leitor de PDF. Posteriormente, o PDF deve ser *flattened*/trancado, o que pode ser feito escolhendo a opção de imprimir o PDF e posteriormente guardar novamente apenas as páginas pretendidas.
- Todos os **gráficos/figuras pedidas**, identificadas com o nome da questão (*e.g.*, "PartI2a.jpg"). Os eixos e pontos devem ser sempre corretamente identificados.
- Os documentos do **compromisso de honra** e da declaração do uso de IA preenchidos e assinados. Ver templates dos mesmos nos anexos A e B.

Uso de IA: Os laboratórios de Introdução à Aprendizagem Automática têm uma política de "semáforo amarelo"quanto ao uso de IA. Permite-se o uso da mesma para auxílio na geração de código e na compreensão de bibliotecas e funções das mesmas. Adicionalmente, é permitido o uso de IA como suporte à aprendizagem ativa. **Todavia, os alunos deverão ser capazes de responder a questões feitas sobre o código durante as aulas, sendo isto contabilizado na componente da avaliação contínua. Não é permitido o uso de IA para gerar respostas.**

[*]https://colab.research.google.com/

3 Avaliação

A nota do mini-projeto I terá em conta o **código entregue**, as **respostas às questões** e a **avaliação contínua** a decorrer durante as duas sessões de laboratório dedicadas a este projeto. A avaliação contínua consistirá na interação com o docente de laboratório, sendo que a mesma poderá ter diferentes formatos. Este projeto terá um peso de 35% na nota final do **laboratório** da cadeira.

4 Dados

4.1 Descrição dos dados

O projeto tem como objetivo principal a análise não supervisionada de vídeos de fisioterapia de vários pacientes que sofreram acidentes vasculares cerebrais (AVC). Os pacientes foram gravados a fazer várias repetições de diferentes atividades diárias, cujo objetivo é promover a reabilitação motora. Os vídeos foram adquiridos usando uma câmera ZED da StereoLabs. Posteriormente recorreu-se ao MediaPipe[†], um modelo baseado em redes neuronais, para a deteção e extração de um conjunto de marcadores a cada 2 segundos de vídeo. Estes marcadores, como exemplificados na Figura 1, correspondem a posições 2D $(u_{j,t}^{(i)}, v_{j,t}^{(i)})$ de várias partes do corpo humano j e podem ser ligados por arestas, permitindo a formação de um esqueleto representativo da pose do paciente no dado instante t.

Formalmente, o conjunto de dados a ser usado consiste em sequências de poses de um número desconhecido de pacientes. Também não são conhecidos os tipos de exercícios que foram executados. Cada sequência $i \in \{0, .., 70\}$ contém um número variável de poses. Cada pose adquirida no instante t é representada por um conjunto de $j \in \{0, ..., 32\}$ marcadores, cada um deles definido por uma posição $(u_{j,t}^{(i)}, v_{j,t}^{(i)})$. Ou seja, dada uma sequência i, cada pose num instante t corresponde ao seguinte vetor: $[u_{0,t}^{(i)}, v_{0,t}^{(i)}, u_{1,t}^{(i)}, v_{1,t}^{(i)}, ..., u_{32,t}^{(i)}, v_{32,t}^{(i)}]$

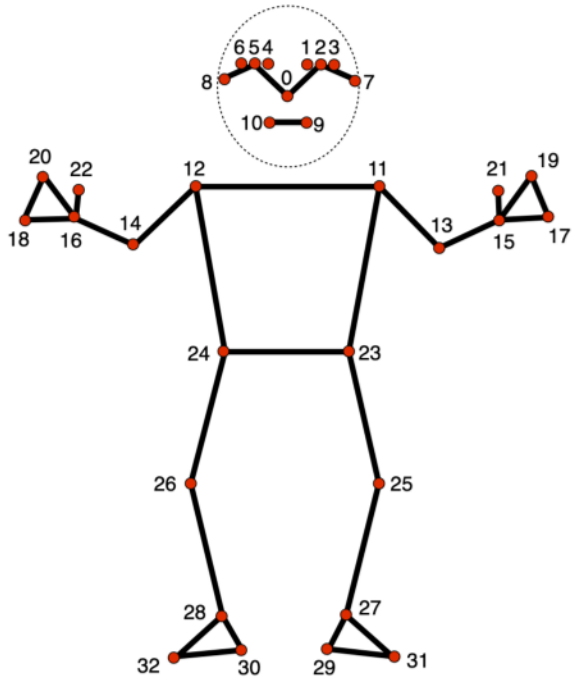


Figura 1: Esqueleto obtido com o MediaPipe Skeleton Keypoints. Cada número corresponde a um marcador e estes seguem a mesma ordem que no projeto.

[†]https://github.com/google-ai-edge/mediapipe

4.2 Upload e navegação preliminar dos dados

Os dados encontram-se guardados no formato pickle (.pkl), podendo ser integrados no código através da biblioteca *pandas*, que criará uma matriz estruturada de dados. O código abaixo providencia alguns exemplos sobre como navegar um:

Listing 1: Código de apoio à leitura e navegação de *dataframes*.

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler

#Importar os dados e verificar dimensões
df_train = pd.read_pickle('Xtrain.pkl')
print(df_train.shape)

#Concatenar todas as poses e sequências numa matriz de dados.
#Esta matriz vai ser usada na maior parte do projeto
X = np.concatenate(df_train['Skeleton_Sequence'].to_numpy())
print(X.shape) # N X 66

#Normalização dos dados - centrar + escalamento (recomendando e crítico para o PCA)
scaler = StandardScaler()
X_norm = scaler.fit_transform(X)

#Aceder a uma sequência específica do dataframe, por exemplo a primeira
seq = df_train.iloc[0]['Skeleton_Sequence']
print(seq.shape) # T X 66
```

Enunciado

Grupo: 19 **Turno:** L04

Nome: João Ribeiro **IST ID:** 113587

Nome: António Ramalho **IST ID:** 114237

Parte I - *k-means*

Esta secção tem como objetivo explorar o algoritmo *k-means*, a sua inicialização e optimização, assim como a aplicação do mesmo aos dados de fisioterapia.

1. **Implementação:** Modifique o código abaixo de forma a implementar o algoritmo *k-means*. O código deve permitir: i) a estimação da posição de K centróides definidos pelo utilizador; ii) a inicialização da posição dos mesmos usando o método aleatório ou o *k-means++*; iii) o cálculo da função de custo; e iv) a associação de novos pontos aos centróides estimados. As funções implementadas devem estar claramente identificadas no código entregue.

Listing 2: Código a modificar para a implementação do *k-means*.

```
import numpy as np

# NÃO MODIFICAR A SEED
np.random.seed(555)

def kminit(X, K, flag):
    #Inicialização - pode ser aleatória ou recorrendo ao k-means++

    '''
    Input:
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra
    K: um inteiro que corresponde ao número de clusters a estimar
    flag: indicador sobre o tipo de inicialização. Sugestão: "random" e "km++"
    para cada versão

    Output:
    C: um numpy ndarray com dimensões (K,d), onde cada linha é a inicialização
    de um dos centróides
    '''

    # A inicialização do primeiro centróide é fixa
    N = X.shape[0]

    C = []
    C.append(X[np.random.randint(N)])

    # TODO: complete o código para inicializar os K-1 centróides de acordo com a flag

    return C


def kmeans_custo(X, C, s):
    #Calcula a função de custo do k-means

    '''
    Input:
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra
```

```
    C: um numpy ndarray com dimensões  (K,d), onde cada linha é a incialização
    de um dos centróides
    s: um numpy ndarray de dimensão (N,) onde cada entrada é um inteiro que representa o
    indíce do cluster para o ponto x^i

    Returns squared Euclidean distances from each point to the center of its assigned cluster
    '''

    # TODO: calcule a função de custo

    return

def kmeans(X, K, flag):
    #Aplica o algoritm k-means à matriz de dados X.

    '''
    X: um numpy ndarray com dimensões (N,d), em que cada linha corresponde
    a uma amostra

    K: um inteiro que corresponde ao número de clusters a estimar

    flag: indicador sobre o tipo de inicialização. Sugestão: "random" e "km++"
    para cada versão

    Devolve um tuplo contendo (C, z):
        C: um numpy ndarray com dimensões  (K,d), onde cada linha é a incialização
        de um dos centróides
        z: um numpy ndarray de dimensão (N,) onde cada entrada é um inteiro
        que representa o indíce do cluster para
        o ponto x^(i)
    '''

    #TODO: Implemente o algoritmo do k-means, com um critério de paragem apropriado.
    #Use as funções definidas acima

    return
```

2. **Selecionar o número de centróides e inicialização**

R2.a) Corra a implementação para os dados de fisioterapia, usando a inicialização aleatória e com um número variável de centróides K. Note que deverá usar uma matriz X que contenha todas as poses, independentemente da sequência. Crie um gráfico do valor função de custo em função do número de centróides, escolha o número óptimo e justifique a escolha.

Para cada K entre 2 e 20, o k-means com inicialização aleatória foi executado uma vez, calculando-se o custo e o silhouette score. As duas métricas apontam para K = 4: o silhouette atinge aí o máximo (cerca de 0,41), e a maior redução do custo ocorre de K = 3 para K = 4 (cerca de 99 000), sendo a seguinte bem menor (cerca de 33 000). A curva apresenta irregularidades, como em K = 7, cujo custo é superior ao de K = 6, sinal de que uma única execução pode ficar presa num mínimo local. Assim, com base nesta run, considera-se o K=4 o número ótimo de centroides.

R2.b) Repita a questão anterior, mas agora utilizando a inicialização do *k-means++*.

Repetiu-se o procedimento com o k-means++. A curva do custo é mais suave, sem as irregularidades da inicialização aleatória. A maior redução ocorre em K = 2 para K = 3 (cerca de 110 000), caindo depois para cerca de 42 000, o que indica um cotovelo em K = 3. O silhouette é máximo em K = 2, mas, excluindo esta divisão demasiado simples, K = 3 apresenta um dos valores mais elevados (cerca de 0,39). Escolheu-se K = 3 para o número ótimo de centroides. A diferença face à alínea anterior mostra que, com uma só execução, o resultado depende da inicialização.

R2.c) Corra 20 vezes cada uma das alíneas anteriores e represente num mesmo gráfico o valor médio da função de custo e o desvio padrão para cada número de centróides K e tipo de inicialização. Qual das inicializações aparenta ser melhor? Porquê?

As diferenças entre as duas inicializações são pequenas e os desvios padrão sobrepõem-se na maioria dos K. Para K = 2 e K = 3, a inicialização aleatória obteve menor custo médio, e o k-means++ maior variabilidade, possivelmente por poder escolher poses atípicas como centroides, o que penaliza mais a solução com poucos clusters. Em K = 4 e K = 5 os resultados são semelhantes. A partir de K = 6, o k-means++ tende a ter custo médio inferior e menor variabilidade. Globalmente, o k-means++ parece ligeiramente melhor para K elevados, sobretudo em consistência.

3. **Visualização:** Escreva código que permita visualizar a pose associada a cada centróide. Use como referência a Figura 1. Não se esqueça de inverter a normalização para recuperar os dados no sistema de coordenadas original.

   R3.a) Com base nas análises feitas nas alíneas anteriores, escolha o melhor modelo e visualize os centróides. Guarde a figura e comente o que observa.

Escolheu-se K = 3 com k-means++ (melhor de 20 execuções). O centroide mais frequente (76% das poses) corresponde à postura neutra: paciente de pé e direito, posição em que passa mais tempo. Nos outros dois, as ancas e os pés mantêm-se, mas a cabeça e os ombros descem e as mãos chegam aos joelhos, indicando flexão do tronco para a frente: num é simétrica, no outro os ombros desviam-se para a direita na imagem, sugerindo inclinação lateral. Sendo médias de muitas poses, os centroides podem ter zonas pouco definidas, como por exemplo , neste caso, as mãos.

4. **Visualização em 2D:** Esta questão deve ser abordada após fazer as alíneas referentes ao PCA. Faça uma projeção 2D dos centróides do modelo escolhido na alínea anterior e dos dados.

   R4.a) Faça um gráfico da projeção obtida, distinguindo os centróides dos restantes pontos. Pinte os pontos de acordo com o centróide a que foram associados. O que pode dizer sobre os clusters? Como se relacionam com as visualizações feitas na questão anterior?

A projeção em 2D mostra três clusters, com uma concentração dominante de pontos próxima da origem, correspondente ao centróide 0 (76% das poses), associado à postura neutra. Os outros dois clusters estendem-se em direções diferentes ao longo das componentes principais, representando movimentos de flexão do tronco, com alguma sobreposição nas zonas de transição. Isto é coerente com os esqueletos da R3.a, nos quais as principais diferenças ocorrem na posição da cabeça e dos ombros, enquanto as pernas permanecem semelhantes. Como as duas componentes explicam apenas 62,84% da variância, a projeção não representa toda a informação usada pelo k-means.

Parte II - PCA e Redução de Dimensionalidade

Esta secção tem como propósito a exploração do PCA como técnica de redução de dimensionalidade e exploração preliminar de um conjunto de dados. Pretende-se também demonstrar como o PCA pode ser utilizado para visualizações de dados de "elevada"dimensão em 2D ou 3D.

5. **Decomposição:** Usando a função `PCA` da biblioteca `scikit-learn`, faça a decomposição da matriz de poses X. Não defina o número de componentes nem o threshold de variância explicada.

   R5.a) Quantas componentes são precisas para obter 95% da variância explicada? Explique os passos que executou para determinar este valor. Se necessário, pode incluir figuras de suporte.

São necessárias 8 componentes. Ajustámos o PCA a X_norm sem definir o número de componentes. A partir do atributo explained_variance_ratio_, que indica a fração da variância total explicada por cada componente (ordenadas por ordem decrescente), calculámos a soma acumulada e identificámos o menor número de componentes para o qual esta atinge 0,95.

   R5.b) Escreva código que permita inspecionar a contribuição de cada característica no espaço original, *i.e.*, os marcadores e as suas componentes (u, v), relativamente a cada componente estimada pelo PCA. Depois, inspecione as componentes identificadas na alínea anterior, reporte o top-10 das *features*/características que mais contribuem e os seus pesos e comente aquilo que observa. Consegue observar alguma relação com os centróides obtidos pelo *k-means* na questão **R3.a)**?

A Figura R5b_top10.png mostra, para cada uma das 8 componentes, as 10 features com maior peso absoluto. Na PC1 (39,0%) e na PC2 (23,8%) dominam os marcadores da cabeça e ombros, com pesos quase uniformes (0,17), sobretudo nas coordenadas v e u, respetivamente. Em conjunto descrevem o deslocamento da parte superior do corpo como um bloco em relação às ancas, isto é, a inclinação do tronco. As restantes componentes têm poucos pesos elevados e descrevem movimentos localizados: perna direita (PC3 e PC5), perna esquerda (PC4), braço esquerdo (PC6), ancas (PC7) e joelhos e mãos (PC8).

Existe uma relação clara com os centróides da R3.a. Projetando-os nas componentes (Figura R5b_centroides_PCs.png), verifica-se que diferem quase só na PC1 e na PC2 (dispersão de 7,29 e 5,88, contra menos de 0,6 nas restantes). O centróide 0, com 76% das poses, fica próximo da origem e corresponde à pose com o tronco direito. Os centróides 1 e 2 têm o tronco inclinado, com a cabeça e os ombros próximos das ancas, distinguindo-se pelo desvio lateral: o 1 afasta-se sobretudo na PC1 (12,23), com o tronco desviado para a direita da imagem, e o 2 na PC2 (−7,88). As pernas são semelhantes nos três, o que é coerente com os valores quase nulos nas PC3 e PC8. O k-means separa portanto as poses ao longo das direções de maior variância identificadas pelo PCA.

6. **Redução de dimensionalidade:** Escreva código para projetar a matriz de dados de fisioterapia numa dimensão mais baixa r, usando r componentes principais. Implemente também uma função que permita reconstruir a matriz de dados a partir da baixa dimensão. Escreva o seu próprio código usando a biblioteca `numpy` e não use funções já feitas do `scikit-learn`.

   R6.a) Faça uma redução de dimensionalidade para $r = 2$. Visualize os dados nesta nova dimensão e descreva o que observa.

A projeção dos dados nas duas primeiras componentes principais apresenta uma região de elevada densidade próxima da origem e prolongamentos em diferentes direções, sem uma separação completamente definida entre grupos. A distribuição sugere movimentos contínuos entre a postura neutra e diferentes posições de flexão. De acordo com a análise da R5.b, a PC1 e a PC2 representam sobretudo deslocamentos da cabeça, ombros e tronco, permitindo visualizar as principais variações posturais dos pacientes.

   R6.b) Qual a variância explicada pelas duas componentes e o erro quadrático médio de reconstrução das poses em X? Em que marcadores/posições é que o erro é maior? Porquê?

As duas primeiras componentes explicam 62,84% da variância total (39,0% pela PC1 e 23,8% pela PC2). O erro quadrático médio de reconstrução nas coordenadas originais é 0,002589. Os maiores erros verificam-se nos marcadores 19, 17, 20, 18, 21 e 22, associados aos dedos das mãos. Isto acontece porque as primeiras componentes descrevem principalmente os movimentos globais da cabeça e do tronco, não conseguindo representar adequadamente os movimentos mais localizados e independentes das mãos, que apresentam maior variabilidade.

R6.c) Repita a projeção e a alínea anterior, mas agora escolhendo r de modo a que o número de componentes explique 95% da variância. Compare os resultados com os obtidos para $r = 2$.

Para explicar pelo menos 95% da variância, são necessárias 8 componentes, que preservam 95,25% da variância total. O erro quadrático médio de reconstrução diminui de 0,002589 (r = 2) para 0,000287 (r = 8), uma redução de aproximadamente 9 vezes. Os maiores erros continuam associados às mãos, mas são significativamente inferiores. Assim, apesar de utilizar quatro vezes mais dimensões, r = 8 permite uma reconstrução muito mais fiel das poses, enquanto r = 2 é mais adequado para visualização e análise exploratória dos movimentos.

Parte III - Misturas de Gaussianas (GMMs)

Esta secção tem como objectivo a exploração de um algoritmo de clustering com uma base probabilística, combinando o mesmo com técnicas de redução de dimensionalidade. Esta parte deve ser abordada após terem sido resolvidas as questões relativas ao PCA.

7. **Estimar um GMM em dimensão reduzida:** Utilizando a projeção obtida na alínea **R6.c)** estime um GMM usando a função `GaussianMixture` do `scikit-learn`. Permita que se estimem as matrizes de covariância completas e defina um número de componentes para a mistura que considere apropriado.

   R7.a) Reporte o número de componentes escolhido e justifique.

Escolheu-se K = 4: na log-verosimilhança negativa, a maior descida ocorre de K = 3 para K = 4 e, a partir de K = 5, os ganhos são pequenos. O silhouette tem um máximo local em K = 4; o máximo global (K = 11) traz um ganho marginal de verosimilhança, e o silhouette, por usar distâncias euclidianas, favorece clusters compactos. K = 4 é ainda próximo do K = 3 do k-means, facilitando a comparação.

R7.b) Utilize o PCA obtido na Parte II para visualizar em 2D os clusters obtidos com o GMM, à semelhança do que fez para o *k-means* na questão **R4.a)**. Expanda o código de visualização para permitir inspecionar também as covariâncias estimadas. Comente o que observa.

As componentes têm formas e orientações muito diferentes. A componente 1 (36% das poses) é compacta e cobre a zona mais densa dos dados. As componentes 0 e 2 são muito alongadas, em direções diferentes, o que sugere movimentos contínuos e não poses estáticas; a 2 estende-se ao longo de PC1, associada à inclinação do tronco. A componente 3 é a mais dispersa e agrupa vários subgrupos, indicando subestrutura que K = 4 não separa. As elipses sobrepõem-se na zona central, onde há pontos de uma componente dentro da elipse de outra; como o modelo foi ajustado em 8 dimensões, estas componentes podem estar separadas nas restantes.

R7.c) Escreva uma função que permita visualizar no espaço original dos esqueletos as poses e respetivas covariâncias (por marcador), tendo por base o GMM estimado na dimensão reduzida. Faça uma figura das poses obtidas e compare os rsultados com os obtidos pelo *k-means*. Comente também aquilo que observa em termos de variância por marcador e pose.

As componentes 0 e 1 têm o tronco direito e distinguem-se pelos braços: na 0 as mãos estão junto às ancas, na 1 à frente do peito. As componentes 2 e 3 têm o tronco fletido, com a cabeça ao nível dos ombros. Os dois clusters de flexão do k-means ficam inteiramente contidos nas componentes 2 e 3, enquanto o cluster neutro (76% das poses) se divide: 73% vai para as componentes 0 e 1 e o restante para as de flexão, que no GMM abrangem também o início do movimento. As covariâncias mostram o que os centróides não mostram: as ancas não variam, por as poses estarem centradas nelas; na componente 1 a variância concentra-se nas mãos, na vertical, indicando o movimento de subir e descer os braços; nas componentes 2 e 3 concentra-se na cabeça e nas mãos, ao longo da trajetória de flexão e possível inclinação. Cada componente descreve assim um movimento, e não apenas uma pose.

8. **Escolher o número de componentes da mistura:** Um dos desafios das GMMs é a escolha do número de componentes. Nesta questão iremos explorar um algoritmo proposto por Figueiredo e Jain[‡] para estimar automaticamente o número de componentes.

   R8.a) Familiarize-se com o artigo de Figueiredo e Jain e explique, sucintamente, como é que os autores propõe estimar automaticamente e de forma não supervisionada o número de componentes de uma mistura. Discuta tambem como é que o método proposto se diferencia do algoritmo EM estudado nas aulas para as misturas de Gaussianas.

[‡]Figueiredo, Mario A. T., and Anil K. Jain. "Unsupervised learning of finite mixture models."IEEE Transactions on pattern analysis and machine intelligence 24, no. 3 (2002): 381-396.

Figueiredo e Jain propõem um método que permite determinar automaticamente o número de componentes de uma mistura finita, como uma mistura de Gaussianas. Para isso, usam o critério MML, que tem em conta a verosimilhança dos dados e a complexidade do modelo. O algoritmo começa com um K elevado e, durante o passo M modificado, atribui peso zero às componentes com suporte insuficiente, eliminando-as. Após cada convergência, remove ainda a componente mais fraca e volta a ajustar o modelo, escolhendo no final aquele que apresenta o menor MML. Ao contrário do EM clássico, que exige definir K à partida e procura maximizar apenas a verosimilhança, este método ajusta automaticamente o número de componentes, penaliza modelos demasiado complexos, reduz a sensibilidade à inicialização e evita problemas de degeneração associados a componentes com covariâncias singulares.

Parte IV - Questões Abertas

Este bloco tem como objetivo promover a iniciativa e creatividade de cada grupo. O objetivo será tirar partido das várias ferramentas de aprendizagem não supervisionada estudadas nas aulas e abordadas nos laboratórios e tentar responder a duas questões sobre os dados recebidos.

9. **Número e tipo de exercícios:** Consegue estimar quantos exercícios diferentes estão representados nas sequências fornecidas sem visualizar as mesmas? E em que consistem os mesmos? Indique um número, tente descrever os exercícios, e explique claramente o procedimento adoptado. Todo o código e figuras utilizadas devem ser submetidos. **Use as ferramentas de aprendizagem não supervisionada - Não deve visualizar as sequências para responder!**

Uma pose é um instante; um exercício é um conjunto de poses ao longo do tempo. Contar clusters de poses não chega: poses neutras aparecem em vários exercícios, e um exercício com várias fases (ex.: inclinação para a esquerda e para a direita) gera vários clusters de pose. Assim, a unidade de análise passou a ser a sequência. Assumiu-se que cada sequência corresponde a um paciente a fazer um único exercício, e que poses do mesmo exercício aparecem juntas nas mesmas sequências.Procedimento (2 níveis):Aplicou-se um GMM às poses projetadas nas 8 componentes principais (95% da variância, 6.c)). Usou-se K_poses = 11, onde o silhouette do R7.a) é máximo (11–13). O objetivo aqui é discriminar poses, não resumi-las; com K_poses = 3–4 as divisões eram demasiado compactas.Cada sequência foi representada por um histograma de 11 posições, com a fração do tempo passada em cada cluster de pose. Aplicou-se o k-means++ da Parte I (melhor de 20 inicializações).Escolheu-se $K_2 = 3$. O cotovelo da função de custo é claro em $K_2 = 3$, e o silhouette tem o máximo em 3 (Ver R9)_K=X.jpg). Para $K_2 > 3$, as novas divisões não são exercícios novos. Um grupo divide-se só pelas proporções dos mesmos clusters de pose, ou seja, por diferenças de amplitude entre pacientes. Outros dão origem a grupos de 4–5 sequências, incompatíveis com um exercício feito por todos os pacientes.Os tamanhos dos três grupos (28/19/24) são razoavelmente equilibrados. Com K_poses = 8 e 13, o máximo mantém-se em $K_2 = 3$ e as tabelas cruzadas mostram partições idênticas: as mesmas sequências nos mesmos grupos. O resultado não depende, portanto, do número de clusters de pose.Descrição dos exercícios (ver figura R9)_movimento.jpg):O movimento foi medido pela variação de cada marcador dentro de cada sequência; como cada sequência é um só paciente, essa variação reflete o movimento e não diferenças entre pacientes. Os dados estão centrados na anca e a câmara é frontal (v = vertical, u = lateral).Exercício 0 (28 seq.) – inclinação lateral do tronco: a cabeça é o que mais se mexe ($v \approx 0.17$), seguida dos ombros, com as pernas quase paradas. O movimento cresce com a distância à anca, como numa rotação do tronco. É o único exercício com componente lateral relevante.Exercício 1 (19 seq.) – elevação alternada das pernas: movem-se pés, tornozelos e joelhos, com tronco e braços parados. As duas pernas sobem (esquerda ≈ 0.14, direita ≈ 0.10), o que aponta para elevação alternada e não de uma só perna. Usa clusters de pose exclusivos (2, 4 e 5).Exercício 2 (24 seq.) – elevação dos braços: movem-se sobretudo mãos e pulsos na vertical, os cotovelos pouco e os ombros quase nada, o que indica rotação em torno do ombro. Alterna entre dois clusters de pose (1 e 6).

10. **Número de Pacientes:** Consegue estimar quantos pacientes fazem parte deste conjunto de dados? Pode assumir que todos os pacientes fazem todos os exercícios. Todavia, poderão apresentar diferentes níveis de constrangimento motor, o que afetará a forma como se movem. Adicionalmente, os pacientes podem ter corpos distintos. Indique um número e explique sucinta mas claramente o procedimento adoptado para chegar ao mesmo. Todo o código e figuras utilizadas devem ser submetidos.

Considerou-se que um paciente se distingue pelas características físicas, pois o movimento depende do exercício, mas o corpo não. Cada sequência foi descrita pelo comprimento de segmentos corporais (ombro–ombro, ombro–cotovelo, etc.), estimado pelo percentil 90 ao longo do tempo: em 2D, um segmento só pode parecer mais curto (quando aponta para a câmara), e o percentil 90 aproxima o comprimento real sem ser afetado por erros pontuais do MediaPipe. Assumiu-se que cada sequência é um paciente a realizar um exercício e que todos realizam os três; como em R9) o menor grupo tem 19 sequências, há no máximo 19 pacientes. Daqui resulta o "teste K/K": num bom agrupamento, cada um dos K grupos contém sequências dos três exercícios.Na versão inicial, verificou-se que alguns segmentos eram afetados pelo próprio exercício. Como todos os pacientes realizam todos os exercícios, a média de cada segmento deveria ser igual nos três exercícios. Foram por isso retirados os segmentos cuja média variava mais de 15% entre exercícios, restando 9 segmentos. Ainda assim, o k-means separava as sequências por exercício (nenhum grupo completo para K ≥ 4), pelo que se subtraiu a cada sequência a média do seu exercício, ficando só a variação entre pacientes. As sequências 11 e 54, isoladas em clusters próprios, foram retiradas como outliers. Os dados foram normalizados (StandardScaler) e aplicou-se o k-means++ (melhor de 20 inicializações) para K entre 2 e 19. O cotovelo indicou K = 4, com 3/4 grupos completos e, para K = 5, 3/5 a 4/5 consoante a corrida; o silhouette foi baixo em todos os K (≈ 0,15–0,21)(ver R10) _SEG=9_SemOUT.jpg). Esta versão aponta para 4 a 5 pacientes, com baixa confiança.De modo a obter-se melhores resultados/testar outra teoria , acrescentaram-se depois segmentos da cara (olhos, orelhas, boca e altura da cara), por serem rígidos. Com um limiar de estabilidade de 10%, mantiveram-se apenas os olhos e um lado da cara, e saiu também o braço esquerdo, ficando 10 segmentos. As sequências 11 e 54 voltaram a ficar isoladas (K = 3 a 5), confirmando que são outliers. Nesta versão, K = 3 é o único K > 2 com todos os grupos completos (3/3), mas o silhouette continua baixo e não há cotovelo claro (ver R10) _SEG=10_SemOUT.jpg). Além disso, com K pequeno os grupos são grandes e é mais provável que contenham os três exercícios por acaso, pelo que o resultado 3/3 é uma condição necessária para um bom agrupamento, mas não uma prova de que este está correto. A amplitude e a assimetria esquerda/direita do movimento(constrangimento motor, observado em R9)) pioraram tanto o teste K/K e como o do silhouette, tendo sido descartadas em ambos as situações. Estima-se que o conjunto de dados contenha entre 3 e 5 pacientes, embora com um grau de incerteza elevado. O silhouette é baixo para todos os valores de K, o que indica grupos sobrepostos, e não existe um cotovelo nítido que identifique um K claramente melhor. O teste K/K, por sua vez, favorece valores de K pequenos. O resultado é também instável, já que, com a mesma configuração, corridas diferentes do k-means produzem variações de ± 1 grupo completo no teste. Por fim, os comprimentos medidos em 2D são ruidosos (dependem da postura, da distância à câmara e de erros do MediaPipe) e as diferenças físicas entre pacientes são pequenas, o que limita a separação possível.

A Declaração de Honra

Cada group deve preencher e assinar a seguinte declaração.

Declaração de Honra

Nós, membros do grupo [número do grupo], identificados abaixo

[Aluno 1], No. [xxxxxx]

[Aluno 2], No. [xxxxxx]

declaramos por nossa honra que este trabalho, realizado ao abrigo da cadeira de Introdução à Aprendizagem Automática é resultado do trabalho dos seguintes membros do grupop: members.

As contribuições individuais são:

[Aluno 1] – [breve descriçao da contribuição]

[Aluno 2] – [breve descriçao da contribuição]

Declaramos que este trabalho é original e que foi feito segundo os regulamentos académicos.

Nome, Número e	Assinatura
_____	_____
_____	_____
_____	_____

Data: _____

B Declaração do Uso de Inteligência Artifiial

Cada aluno deve preencher e assinar uma cópia individual desta declaração.

Declaração do Uso de Inteligência Artificial

Nome do Aluno: _____

Número do Aluno: _____

Declaro que todas as decisões e conteúdo técnico deste laboratório são da minha autoria.

- [listar ferramenta] para [finalidade]

Declaro que compreendo completamente o funcionamento de todas as componentes do projeto, mesmo as que foram desenvolvidas com o apoio das ferramentas de IA listadas acima."

Data: _____ Assinatura: _____